

中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

题 目

基于目标检测的高速公路应急车道实时启用策略研究

摘 要：

高速公路拥堵现象的原因众多，最典型的的就是部分路段出现瓶颈现象，主要原因是车辆汇聚，而拥堵后又容易蔓延。适时开放应急车道能有效改善高速公路拥堵状况，并能一定程度地提高高速公路运行安全性。通常情况下，应急车道是救生通道，不能随意占用，但若合理使用，可以有效避免拥堵。因此，探索如何合理使用应急车道并评估临时借用应急车道对缓解道路拥堵的作用具有重要的理论和现实意义。

问题 1：本文首先基于 YOLOv10m 和 ByteTrack 算法对 4 个观测点的视频数据进行过线统计，得到基本统计量（流量 q 、速度 u 和密度 ρ ），将结果保存为观测点 a_metrics.xlsx 等四个文件。并基于 ARIMA 模型分析交通流数据，对比了拥堵状态和非拥堵状态的曲线特征。然后基于最小二乘法对交通流数据进行拟合分析，获取了密度-速度，流量-密度，流量-速度关系。根据 A,B,C 观测点游密度特征递推 10 分钟后与 D 观测点依旧较高的相关性，利用多元回归和 AdaBoost 模型实现了提前 10 分钟预警。在测试集数据中，AdaBoost 模型的平均绝对误差为 11.2veh/km，均方根误差为 19.9veh/km，R2 值为 0.968，达到了较高的预测精度。其次，基于间断交通流方程理论建立交通流拥堵模型，检测持续拥堵情况并进行提前预警。最后根据实际视频信息对所建立的交通拥堵模型进行检验，选取了观测点 D 在 12:56 和观测点 C 在 13:26 的拥堵状况，计算出 D 点和 C 点的最短拥堵持续时间分别为 25 分钟和 38 分钟，与实际的拥堵持续时间进行对比，判断出 CD 段发生持续拥堵，BC 段未发生持续拥堵，判断结果均正确，从而验证了该拥堵模型的有效性。

问题 2：综合利用各个交通流参数，提出了针对每两个观测点之间路段的区间占用率模型，将区间内的车流状况用占用率函数 $K(t)$ 量化表示，为启用应急车道提供重要依据。为了综合利用 AB 段和 BC 段的各自路段的占用率 K 值，依据 CD 路段的距离大小设置 K_{AB} 和 K_{BC} 的权重，从而确定采用 $K = 0.4K_{AB} + 0.6K_{BC}$ 描述上游路段的拥堵状况。据此，本文提出了 3 个关键的应急车道启用依据。依据一：上游路段车辆数较多，需要提前对 CD 开放应急车道，该依据通过 K 值大于 0.8 判定；依据二：下游路段不能处于拥堵状态，通过 D 路口的监控数据 ρ_D 小于

0.8 判定。**依据三：**应急车道利用率 U_i 如果低于一定水平就选择关闭，该依据通过第四问的车道利用率模型进行补充。

问题 3：对应急车道启用的具体效果进行了量化分析。通过区间占用率模型进行量化计算，对比了应急车道开放前后的 CD 路段的车道占用率 $K(t)$ 曲线，结果表明，采用应急车道后，D 观测点的拥堵时间往后推迟了 3 分钟，拥堵的结束时间提早了 25 分钟，总堵塞时间**降低了 48.3%**。

问题 4：下游路段的拥堵状态是能否开启应急车道的重要依据，为此本文提议在 D 的下游布置一个摄像头 E，从而对 DE 区间建立车辆占有率模型。通过计算 K_{DE} 能够帮助描述下游 DE 的拥堵情况，为应急车道的开发提供更加可靠的理论依据。此外，考虑到 CD 区间较长，本文提议在 CD 区间内部布置一个摄像头 F，建立**应急车道利用率模型**，用于计算应急车道开发后的利用率水平 U，从而判断是否应该及时关闭应急车道，进一步完善了应急车道开发/关闭的判断流程图。此外，基于 YOLO 模型的检测会受遮挡因素影响，产生漏检问题，所以本文提议将摄像头的位置布置到车道正上方，角度应当是俯视车道，降低遮挡情况，减少车流量漏检，提升 YOLO 模型对车流量参数统计的精度。

关键词：车辆统计；目标检测（YOLO）；目标追踪（ByteTrack）；应急车道；拥堵预警；区间占用率；

目录

一、 问题重述.....	6
1.1 问题背景.....	6
1.2 问题重述.....	6
二、 模型假设与符号说明.....	7
2.1 模型假设.....	7
2.2 符号说明.....	7
三、 问题一：交通流参数变化规律及拥堵模型.....	8
3.1 问题分析.....	8
3.2 视频信息提取与处理.....	9
3.2.1 视频信息预处理.....	9
3.2.2 基于 YOLOv10 的车辆检测	10
3.2.3 基于 ByteTrack 的车辆追踪.....	11
3.2.4 基于过线计数的车辆统计.....	12
3.2.5 车流量信息统计与分析.....	13
3.3 交通流数据的数值特征分析.....	17
3.3.1 ARIMA 模型建立	18
3.3.2 密度特征分析.....	18
3.3.3 流量特征分析.....	19
3.3.4 速度特征分析.....	20
3.4 交通流参数的拟合关系分析.....	20
3.4.1 连续交通流模型.....	20
3.4.2 密度-速度关系	22
3.4.3 流量-密度关系	23
3.4.4 流量-速度关系	25
3.5 基于间断交通流方程的交通流拥堵预警模型.....	27
3.5.1 模型建立.....	27
3.5.2 预警方法.....	31
3.6 基于上游密度特征的下游交通流密度预测模型.....	31
3.6.1 不同观测点交通流参数的时间传递关系.....	31
3.6.2 基于多元线性回归的密度预测.....	33
3.6.3 基于 AdaBoost 回归的密度预测.....	34
3.6.4 基于密度预测模型改进的交通流拥堵预警方法.....	36
3.7 基于视频信息的模型验证.....	37
3.7.1 拥堵阈值选择.....	37
3.7.2 数据来源.....	40
3.7.3 模型验证.....	42
四、 问题二：应急车道启用决策依据.....	44
4.1 问题分析.....	44
4.2 应急车道的启用依据.....	44
4.3 基于区间占用率的应急车道启用模型.....	44
4.3.1 模型建立.....	44
4.3.2 模型应用与分析.....	45

4.4 结论.....	47
五、 问题三：应急车道启用效果量化分析.....	49
5.1 问题分析.....	49
5.2 基于占有率模型的应急车道启用流程.....	49
5.3 量化分析--应急车道启用前.....	50
5.4 量化分析--应急车道启用后.....	51
5.5 结论.....	52
六、 问题四 视频监控点优化布置.....	53
6.1 问题分析.....	53
6.2 摄像头的区间位置优化.....	53
6.2.1 下游位置添加 E 点	53
6.2.2 CD 区间内部添加 F 点.....	54
6.3 摄像头的角度布置优化.....	56
6.4 安全性问题.....	57
七、 参考文献.....	59
八、 附录.....	60

一、问题重述

1.1 问题背景

高速公路具有行车速度快、流量大、有限开放性、大空间性等特点，由于这些特点，也极易引起突发事件，导致高速公路通行能力下降，严重影响了运营效率与行车安全^[1]。高速公路建设时，往往会在右侧增设应急车道，以应对工程救援、消防救援、医疗救护等应急车辆需求。适时开放应急车道能有效改善高速公路拥堵状况，并能一定程度地提高高速公路运行安全性。

通常情况下，应急车道是救生通道，不能随意占用，但若合理使用，比如在某路段通过上、中、下游交通流量的监控发现很有可能会发生拥堵，而该路段没有发生事故的情况下，允许使用应急车道，及时降低车流密度，很有可能会避免一次大拥堵^[2]。因此，建立数学模型发掘高速公路特定路段即将发生拥堵的条件，探索如何合理使用应急车道并评估临时借用应急车道对缓解道路拥堵的作用具有重要的理论和现实意义^[3-5]。

1.2 问题重述

问题一：该道路路段长度 5000m，并设有 2 个行车道及 1 个应急车道，总共四个视频观测点。需要基于此路段的视频数据解决如下问题：

(1)交通流参数会因为道路实际情况有着不同的变化规律，统计四个观测点的交通流参数随时间的变化规律，为后续建模奠定基础。

(2)需要根据现有数据建立交通流拥堵模型，利用交通流在四个观测点的基本参数以及道路情况给出从第三点到第四点之间路段可能出现持续拥堵状态，进行实时预警，并给出依据；

(3)利用视频数据验证模型的有效性。

问题二：构建合理启用高速公路应急车道的模型，为决策者提供临时启用应急车道决策的依据。

问题三：利用监控数据，设计应急车道启用决策模型，针对实际交通状况实时决策是否启用应急车道，并量化启用应急车道的作用。

问题四：上述提到的监控点是在之前就已经规划并安装的，其设计初衷并未涵盖对应急车道临时启用的特殊情况进行考量。为了增强从第三个点到第四个点之间路段在需要时能够迅速且合理地启用应急车道的决策能力，同时确保成本效益，针对重新规划并布置该路段的视频监控点给出方案。

二、模型假设与符号说明

2.1 模型假设

1. 假设道路上没有突发影响交通流的特殊事件。
2. 假设 4 个观测点之间不存在其他出入口。
3. 假设所有车辆的物理特性一致，例如车辆的长度、宽度等参数一致。
4. 假设模型中车辆行驶条件均为正常天气状况。

2.2 符号说明

符号	名称	单位
q	流量	veh/min
ρ	密度	veh/km
u	速度	km/h
$\bar{V}$	区间路段平均行程速度	km/h
L	区间路段长度	km
t_i	车辆 i 通过区间路段的时间	h
ρ_m	最大密度	veh/km
ρ_0	初始密度	veh/km
u_m	最大速度	km/h
t_d	堵塞消失时刻	time
x_s	出现堵塞的位置	km
Q_m	区间最大容纳水平	veh

三、问题一：交通流参数变化规律及拥堵模型

3.1 问题分析

问题一要求根据提供的各个观测点的视频监控信息,进行交通流参数分析并建立交通流拥堵模型进行交通拥堵预警^[6-10]。本文将题目要求分为三个部分亟待解决:

针对第一小问,首先,合并采集到的四个观测点的视频数据并都视频信息,利用 YOLOv10 模型检测车辆,输出其位置信息,并基于 ByteTrack 算法进行车辆追踪,对检测到的车辆进行过线统计以得到车辆的流量,密度及速度;然后,基于 ARIMA 模型对数据进行分析以得到交通流参数的数值特征,并基于最小二乘法对连续交通流模型进行数据拟合,分别得到密度-速度,流量-密度,流量-速度关系。针对第二小问,首先建立基于间断交通流方程的拥堵预警模型检测拥堵情况并进行提前预警;然后建立基于上游密度特征的下游交通流密度预测模型,预测达到预警时刻后的下游交通流密度用于改进交通拥堵预警模型,提升预警的精确度。针对第三小问,通过视频数据选取观测点 D 的拥堵路段作为验证数据,以此来验证交通拥堵预警模型的可行性。整体流程如图 1 所示。




图 1 问题一分析流程图

3.2 视频信息提取与处理

3.2.1 视频信息预处理

由于每个子文件夹下视频时间上是连续的，所以，为了便于后续处理，对同一个监控点的多个视频数据进行合并，汇总成四个视频，分别对应高速观测点 107，105，108 和 103 的视频数据，命名为观测点 A 视频，观测点 B 视频，观测点 C 视频和观测点 D 视频。如图 2 所示，视频监控时间存在一个公共区间，每个视频开始的时间和结束时间不相同，具体汇总信息如表 1 所示。




图 2 四个观测点视频区间情况

表 1 四个观测点视频信息统计

观测点视频	开始时间	结束时间	总时长
A	2024-05-01 11:41:03	2024-05-01 16:14:32	4 小时 33 分 29 秒
B	2024-05-01 11:52:27	2024-05-01 15:28:20	3 小时 35 分 53 秒
C	2024-05-01 11:35:43	2024-05-01 16:09:12	4 小时 33 分 29 秒
D	2024-05-01 12:56:47	2024-05-01 15:20:04	2 小时 23 分 17 秒

3.2.2 基于 YOLOv10 的车辆检测

YOLO 系列算法是目前较为流行的目标检测算法^[11]，该算法可以通过从输入到输出的模型结构直接得到最终的输出，通过预测物体的类别概率和位置坐标值来实现目标实时检测。YOLOv10 由清华大学团队于 2024 年发布^[12]，该架构被认为是用于多尺度目标检测的最先进的卷积神经网络结构之一^[13,14]。模型整体架构依然是典型的特征金字塔网络^[15]（Feature Pyramid Network, FPN）结构。

如图 3 所示，模型主要分为三部分：骨干网络（Backbone），颈部（Neck）和检测头（Detection Head）。骨干网络用于特征提取，颈部部分负责对骨干网络提取的特征进行多尺度特征融合，并将这些特征传递给预测层，检测头主要负责进行最终的回归预测^[16]。最后，输出端是模型预测的结果，包括每个目标的类别及其对应的边界框坐标和概率值等信息。




图 3 YOLOv10 模型架构

3.2.3 基于 ByteTrack 的车辆追踪

ByteTrack^[17]算法是一种基于目标检测的追踪算法，结合目标追踪所得到的位置信息进行追踪。追踪算法使用了卡尔曼滤波预测边界框，然后使用匈牙利算法进行目标和轨迹间的匹配^[18]。

(1) 卡尔曼滤波

卡尔曼滤波^[19]能根据前一帧的状态预测下一帧的状态，用于解决视频中目标快速移动或被短暂遮挡的问题。如图 4 所示， $\mathcal{N}(\hat{x}_{k-1}, \hat{p}_{k-1})$ 表示前一帧目标的位置，基于前一帧的信息预测得到下一帧目标车辆的位置为 $\mathcal{N}(\hat{x}_k, \hat{p}_k)$ ，YOLOv10 对车辆的检测定位为 $\mathcal{N}(y_k, R_k)$ ，最终得到的位置信息是前一帧预测结果和检测模型定位结果的加权组合 $\mathcal{N}(\hat{x}_k, \hat{p}_k)$ 。当目标被短暂遮挡时，YOLOv10 检测无法到车辆，应用卡尔曼滤波能预测车辆的位置，从而很好地解决这一问题。




图 4 卡尔曼滤波原理

(2) 匈牙利算法

匈牙利算法^[20]用于解决前后帧多目标匹配问题，通过识别连续帧之间每个目标之间的关联性实现。如图 5 (a)所示，当视频的前后帧都只有一个目标，二者能够很容易实现匹配，但如果出现图 5(b)所示的情况，视频后一帧中出现了多个目标，就可以用匈牙利算法实现目标的匹配，解决目标与检测框之间的匹配问

题，确保目标 ID 的一致性。




图 5 目标匹配问题示意图

因此，在基于 YOLO 的多目标跟踪算法中，YOLO 输出边界框和对应的置信度。在下一帧处理之前，卡尔曼滤波器根据上一帧 YOLO 检测结果及当前跟踪状态（位置、速度），预测每个目标在下一帧中的可能位置。这是为了在跟踪过程中应对目标短暂消失或遮挡的情况，提供一个合理的估计位置。当 YOLO 在当前帧中检测出新的边界框后，匈牙利算法将这些检测框与卡尔曼滤波器预测结果进行匹配，从而确定每个检测框的归属。

3.2.4 基于过线计数的车辆统计

如图 6 所示，水平直线段为设定的车辆统计线，曲线为每一帧中车辆的运动轨迹，分别代表车辆 1 和车辆 2。




图 6 两线段相交判断示意图

(1) 坐标点：

设统计线的两个端点为 $P_1(x_1, y_1)$ 和 $P_2(x_2, y_2)$ ，车辆轨迹线段的端点为 $Q_1(x_3, y_3)$ 和 $Q_2(x_4, y_4)$ 。

(2) 计算方向向量

统计线段的方向向量为:

$$\mathbf{D}_1 = \mathbf{P}_2 - \mathbf{P}_1 = (x_2 - x_1, y_2 - y_1) \quad (1)$$

车辆轨迹线段的方向向量为:

$$\mathbf{D}_2 = \mathbf{Q}_2 - \mathbf{Q}_1 = (x_4 - x_3, y_4 - y_3) \quad (2)$$

(3) 判断线段是否平行:

计算向量叉积 d :

$$d = \mathbf{D}_1 \times \mathbf{D}_2 = (x_2 - x_1)(y_4 - y_3) - (y_2 - y_1)(x_4 - x_3) \quad (3)$$

如果 $d = 0$, 则两个向量平行或共线, 不相交, 则视为车辆不过线。

(4) 计算参数 t 和 u

当 $d \neq 0$ 时, 求解参数 t 和 u , 使得: $\mathbf{P}_1 + t\mathbf{D}_1 = \mathbf{Q}_1 + u\mathbf{D}_2$, 解得:

$$t = \frac{(\mathbf{Q}_1 - \mathbf{P}_1) \times \mathbf{D}_2}{d} \quad (4)$$

$$u = \frac{(\mathbf{Q}_1 - \mathbf{P}_1) \times \mathbf{D}_1}{d} \quad (5)$$

其中, 向量叉积定义为: $\mathbf{A} \times \mathbf{B} = A_x B_y - A_y B_x$

故,

$$\begin{aligned} & (\mathbf{Q}_1 - \mathbf{P}_1) \times \mathbf{D}_2 \\ &= (x_3 - x_1)(y_4 - y_3) \\ & - (y_3 - y_1)(x_4 - x_3) (\mathbf{Q}_1 - \mathbf{P}_1) \times \mathbf{D}_1 \\ &= (x_3 - x_1)(y_2 - y_1) - (y_3 - y_1)(x_2 - x_1) \end{aligned} \quad (6)$$

(5) 判断交点是否在两条线段上:

若公式(7)成立, 则两线段相交, 交点在两条线段的范围内。否则, 线段不相交。

$$\begin{cases} 0 \leq t \leq 1 \\ 0 \leq u \leq 1 \end{cases} \quad (7)$$

3.2.5 车流量信息统计与分析

针对四个观测点的视频采用基于 YOLOv10 和 Bytrack 追踪的过线统计, 以获取交通三要素 (流量 q , 速度 u 、密度 ρ) 的值。图 7 给出检测过程图。黑色线条对应车辆轨迹, ID 号为目标追踪算法为每一辆车分配的 ID。Conf 是目标检测算法对检测结果的置信度水平, 置信度水平越高表明检测物体为车辆的可能性越高。统计内容包含过线车辆总数, 当前车辆平均速度和当前视频中的车辆数目, 如图 7-图 10 所示, 分别对应观测点 A, B, C, D。



图 7 观测点 A 目标检测和信息统计提取过程展示




图 8 观测点 B 目标检测和信息统计提取过程展示



图 9 观测点 C 目标检测和信息统计提取过程展示




图 10 观测点 D 目标检测和信息统计提取过程展示

4 个观测点的完整统计结果可参见附件“观测点_a.xlsx”，“观测点_b.xlsx”，“观测点_c.xlsx”，和“观测点_d.xlsx”，其中“观测点_a.xlsx”的部分结果展示如表 2 所示。

表 2 视频 A 的统计结果

帧序列	时间(s)	平均速度(px/s)	当前帧车辆数	过线车辆总数
0	0	0	7	0
...	...	...	...	...
29669	8990.60	57.46	6	4873
29670	8990.90	57.45	4	4873
29671	8991.21	57.44	4	4873
29672	8991.51	57.47	4	4873
29673	8991.81	57.47	4	4874
...	...	...	...	...
54647	16559.69	54.09	8	7835

由示例表数据可知，随着时间（帧）的变化，速度、当前车辆数和过线车辆总数都在不断变化，但每一帧之间间隔较短，在很段的时间内，过线车辆数变化不大，因此，基于每 1 分钟进行一次三个交通路基本参数的统计。

给定交通三要素的计算说明如下：

流量 $q(x, t)$ 定义为时刻 t 单位时间内通过点 x 的车辆数。根据每个单位时间内“过线车辆总数”进行计算，方法如下：第一个 1 分钟的流量值 q 为第 1 分钟末的“过线车辆总数”减去第一分钟的“过线车辆总数”。第二个 1 分钟的流量值 q 为第 2 分钟的“过线车辆总数”减去第 1 分钟的“过线车辆总数”。以此类推，获取每一个 1 分钟对于车流量数据 $q(x, t)$ 。

密度 $\rho(x, t)$ 定义为时刻 t 点 x 处单位长度内的车辆数。根据视频中“当前帧车辆数”计算，以每 1 分钟为一个单位时间。方法如下：第一个 1 分钟的密度为这 1 分钟内（0 分钟-1 分钟）“当前帧车辆数”的平均值除以摄像头中车道长度（设置为 L ，假设为 50m）；第二个 1 分钟的密度就为第 1 分钟到第 2 分钟的“当前帧车辆数”的平均值除以摄像头中车道长度。以此类推，计算得到每一个时间单位对应的密度 $\rho(x, t)$ 。

速度 $u(x, t)$ 的计算基于“平均速度”的值进行计算，方法如下：第一个 1 分钟的速度为这 1 分钟内（0-1 分钟）“平均速度”的平均值然后乘以单位换算比例，将其换算为 km/h；第二分钟的速度就为第 1 分钟到第 2 分钟的“平均速度”的平均值乘以换算比例。以此类推，计算得到每一个 1 分钟的对应的速度 $u(x, t)$ 。

因此，将上述统计结果进行转换，从而得到交通流基本参数（流量、密度和速度）的结果，如表 3 所示。

表 3 观测点 A 的交通流基本参数统计结果示例表

时间	流量(veh/min)	密度(veh/m)	速度(km/h)
0-1	38	0.170	53.504
1-2	36	0.156	48.979
2-3	36	0.166	48.448
...	...	...	...
272-273	45	0.130	54.144
273-274	23	0.071	54.140
274-275	27	0.083	54.113

每个视频的完整统计结果都放到了附件，名称为：“观测点 a_metrics.xlsx”，“观测点 b_metrics.xlsx”，“观测点 c_metrics.xlsx”和“观测点 d_metrics.xlsx”。下面给出这些观测点的交通流数据的可视化展示与分析。

观测点 A 情况：如图 11 所示，三条曲线分别为密度曲线、流量曲线和速度曲线。从密度和流量曲线可知，前半程的密度和车流量较大，后半程较小。比对原始视频，表明基于目标检测算法得到的统计结果的趋势能够反应真实情况。




图 11 观测点 A 信息统计结果与实际情况对照

从速度曲线可知，前一个小时的速度相对较小（因为密度较大），但后续密度减小，速度就开始上升。总体来说，观测点 A 的车流量速度基本都在 58km/h 以上，速度较大，尚未出现交通拥堵。

观测点 B 情况：观测点 B 的流量和密度曲线与观测点 A 类似，通过查看原始视频（可参见图 12 右侧的视频截图），证实了这样情况。



图 12 观测点 B 信息统计结果与实际情况对照

观测点 C 情况：观测点 C 的流量和密度曲线（尤其是密度曲线）与观测点 A,B 趋势相似，前半程车流量和密度相对较大，后半程相对较小，比对实际视频同样得到了验证。




图 13 观测点 C 信息统计结果与实际情况对照



图 14 观测点 D 信息统计结果与实际情况对照

同样的，观测点 D 的流量和密度曲线呈现前半程较大，后半程相对较小情况。与观测情况一致。然而，与前 3 个观测点不同的是，观测点 D 的密度、流量和速度曲线在 70-80 分钟时，出现了断崖式变化的情况，密度和流量显著减小，速度显著增大。通过原始视频可知 D 观测点出现了严重的交通拥堵现象，而在视频的 70-80 分钟（实际 14:08-14:18）时间段拥堵情况消失，密度减小，速度也显著增加。

如图 15 所示，将上述 12 条曲线（4 个观测点×3 个特征量）汇总。对于流量和密度曲线（尤其是密度曲线），可以看到观测点 A、B 和 C 都呈现前期较大，后期较小的情况，这是因为这三个观测点相距较近（都是 1km），所以流量和密度随着时间的变化较为一致，而观测点 D 相距较远，且观测点发生了交通拥堵，所以与 A,B,C 3 个观测点的分布差异较大。




图 15 不同观测点车流量、密度和速度曲线

3.3 交通流数据的数值特征分析

由于观测点 D 拥堵特性较为明显，故选取 D 视频进行数据分析。注意到视频中，D 路口的视频被分成了两段，**拥堵阶段（前半程）**以及拥堵解除后的**稀疏流阶段（后半程）**。因此，可以基于 ARIMA 模型的参数对这两段视频的交通流参数特征进行描述分析。

3.3.1 ARIMA 模型建立

ARIMA 模型是一种广泛使用的时间序列预测统计方法^[21]。ARIMA 模型可以被视为一个“过滤器”，通过将信号与噪声分开，并将信号外推到未来以获得预测，ARIMA 模型流程图如图 16 所示。




图 16 ARIMA 模型流程图

模型如公式(8)所示：

$$ARIMA(p, d, q) = \begin{cases} AR(p) - p \text{ 阶自回归} \\ MA(q) - q \text{ 阶滑动平均} \\ d - \text{为达平稳所需的差分次数} \end{cases} \quad (8)$$

参数说明：

自回归阶数 p：表示模型使用多少个过去的时间点来预测当前的值。

移动平均阶数 q：表示模型中使用多少过去的白噪声（随机干扰）项的线性组合来预测当前值。例如， $q=0$ 表示模型不包括移动平均项。

差分阶数 d：表示时间序列进行差分的次数，用于使时间序列平稳。

3.3.2 密度特征分析

拥堵阶段：对于 D 路口拥堵阶段密度，ARIMA 的结果为 $d=2, p=0, q=1$ 。如图 17 所示，其中， $q=1$ 表明移动平均项为 1，表示模型考虑前一个时间点的随机冲击对当前值的影响。短期的随机冲击会对后续值产生影响，但这种影响不会持续很长时间，这表明拥堵正在得到缓解，符合实际情况，后续交通拥堵得到缓解，密度出现了跳跃式下降。

稀疏流阶段：对于 D 路口稀疏流阶段密度，ARIMA 的结果为 $d=0, p=2, q=0$ 。其中， $d=0$ 表明不需要进行差分，原始数据已经达到平稳状态。这表明稀疏交通流阶段，D 路口的密度没有明显的趋势或周期性变化。而自回归阶数 $p=2$ 表明当前流量与前两个时间点的流量有直接的线性关系。




图 17 密度特征曲线

3.3.3 流量特征分析

拥堵阶段: 对于 D 路口拥堵阶段流量, ARIMA 的结果为 $d=1, p=3, q=2$, 如图 18 所示。 $d=1$ 表明数据需要一阶差分才能达到平稳, 说明原始流量序列存在一定的非平稳性。 $p=3$ 表示当前流量与前三个时间点的流量有直接的线性关系, 反映出流量变化具有较强的"记忆性"和惯性。 $q=2$ 意味着模型考虑了前两个时间点的随机冲击, 表明短期的随机因素会对流量产生持续影响。

稀疏流阶段: 对于 D 路口稀疏流阶段流量, ARIMA 的结果为 $d=0, p=2, q=1$ 。 $d=0$ 表明原始数据已经平稳, 没有明显的趋势或周期性变化。 $p=2$ 意味着当前流量与前两个时间点的流量有直接的线性关系, 但这种关系比拥堵阶段弱。 $q=1$ 表示只考虑了前一个时间点的随机冲击, 说明短期随机因素的影响较小且持续时间短。这些特征反映了稀疏流阶段流量的相对稳定性和可预测性。

如图 18 所示, 拥堵阶段的流量曲线波动较大, 尤其在 14:00 至 14:15 之间有显著的上升趋势。相比之下, 稀疏流阶段的流量曲线更加平稳, 波动幅度明显减小, 这种变化反映了交通状况从拥堵到畅通的转变过程。




图 18 流量特征曲线

3.3.4 速度特征分析

拥堵阶段：对于 D 路口拥堵阶段速度，ARIMA 计算结果为 $d=2, p=4, q=0$ 。如图 19 所示， $d=2$ 表明数据需要二阶差分才能达到平稳，这意味着原始速度序列具有很强的非平稳性，可能存在复杂的趋势或加速度变化。 $p=4$ 表示当前速度与前四个时间点的速度有直接的线性关系，反映出速度变化具有较长的"记忆性"和强烈的时间依赖性。 $q=0$ 意味着模型不考虑移动平均项，表明随机冲击对速度的影响不显著或持续性很短。

稀疏流阶段：对于 D 路口稀疏流速度，ARIMA 计算结果为 $d=2, p=0, q=0$ 。 $d=2$ 同样表明需要二阶差分才能达到平稳，说明即使在稀疏流阶段，速度仍然表现出非平稳的特性。 $p=0$ 和 $q=0$ 意味着模型既不包含自回归项也不包含移动平均项。这种情况下，速度的变化可能主要由确定性趋势或周期性因素驱动，而不是由历史值或随机冲击决定。

如图 19 所示，拥堵阶段的速度曲线在大部分时间内相对稳定，但在 14:00 至 14:15 之间出现了显著的上升趋势，这反映了交通状况开始改善的过程。相比之下，稀疏流阶段的速度曲线呈现出一个急剧上升后保持稳定的状态，这种突然的变化对应于交通拥堵的快速缓解。

速度特征的变化反映了交通状况从拥堵到畅通的转变过程。拥堵阶段速度的复杂动态和强时间依赖性说明了交通流处于一个相对受限和不稳定的状态。而稀疏流阶段速度的突然提升和随后的稳定表明交通条件得到了显著改善，进入了一个更加自由流动的状态。




图 19 速度特征曲线

3.4 交通流参数的拟合关系分析

若假设研究对象是在无穷长公路上沿单向运动的一条车流，假定不允许超车，公路上也没有岔路，即汽车不会从其它通道进入公路或从公路驶出。则就可以把车队看作连续的流量。连续交通流模型将交通流抽象为类似于流体的连续介质，而现实中的交通是由离散的个体（车辆和驾驶员）组成，具有随机性和复杂性。因此，有必要对实际的交通流参数间的关系进行分析，有利于后续建模。

3.4.1 连续交通流模型

连续交通流模型基于宏观视角，将整个交通流作为一个连续的流体来处理，

而不关注每一辆车的细节。这样可以更有效地分析大规模的交通流动情况，如城市主干道、高速公路等长路段的交通状态。这在处理数以千计的车辆流动时非常有用。

若将交通流视为一维流体场，其流量、密度和速度 3 个基本参数之间存在密切关系，如公式(9)所示，单位时间内通过的车辆数等于单位长度内的车辆数与车流速度的乘积^[22]。

$$q(x, t) = u(x, t) \times \rho(x, t) \quad (9)$$

通过分析流量 q 与密度 ρ 之间的关系，车流速度 u 总是随着车流密度 ρ 的增加而减小。当一辆车前面没有其他车辆时($\rho = 0$)，它将以最大速度行驶($u = u_m$)；当车队首尾相接造成堵塞时($\rho = \rho_m$)，车辆无法前进($u = 0$)。在此两种情况下，车流量 $q=0$ 。进一步观察可以发现，当 ρ 较小时，随着 ρ 的增加 q 也会增长；但当 ρ 较大时， q 将随着 ρ 的增加而减小。故将流量 q 与密度 ρ 之间的关系用开口向下的二次函数表示，如公式(10)所示。设 $\rho = \rho^*$ 时 q 达到最大值 q_m ，将公式(9)代入公式(10)中，可得公式(11)。显然， q 的极大值点 $\rho^* = \rho_m/2$ 。

$$q = u_m \rho \left(1 - \frac{\rho}{\rho_m}\right) \quad (10)$$

$$u = u_m \left(1 - \frac{\rho}{\rho_m}\right) \quad (11)$$

公式(10)和公式(11)是在平衡状态下 ρ, u 和 q 之间的关系，即假定所有车辆的速度相同，公路上各处的车流密度相同。

但是当初始密度 $f(x)$ 表示前面车辆拥挤，后面车辆稀疏，于是后面的车速比前面大。然而在高速公路上，当车速快的汽车追上车速慢的汽车又不能超速的时候，速度就会突然降下来，并且会引起后面汽车的连锁反应。速度的突变必然会导致密度和流量的突变，形成间断。因此，在实际交通流中不能使用微分方程描述车流的分布。需要针对实际的交通流数据，进一步对参数之间的关系进行分析。

基于高速公路交通流的特点，通过模型拟合的方式分析不同交通流参数之间的关系。选取 Greenberg 模型、Pipes 模型和 Van Aerde 模型对观测点 A、B、C、D 的交通流数据进行拟合，分别表示乘积关系、正比关系和反比关系。对拟合结果进行评价，以进一步分析不同参数之间的关系。拟合模型如下：

Van Aerde 模型：该模型考虑了速度、密度和流量之间的非线性关系，其形式为：

$$u = \frac{u_{max}}{1 + \alpha \rho + \beta \rho^2} \quad (12)$$

其中， u_{max} 是最大速度， α 和 β 是模型参数。

Pipes 模型：为一种线性模型，是公式(11)的简化形式。通常表示为：

$$u = u_{max} - k \cdot \rho \quad (13)$$

其中， k 是模型参数，表示速度随密度变化的速率

Greenberg 模型：是一种交通流模型，通常用于描述速度与密度之间的关系，其公式为：

$$u = u_{max} \cdot \ln \left(\frac{\rho_{max}}{\rho} \right) \quad (14)$$

对于拟合结果采用对比均方误差、平均绝对误差、平均相对误差和决定系数的方式进行综合评估。定义如下：

均方误差 (MSE)：评估模型预测值与实际值之间的平均平方误差，公式为：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (15)$$

平均绝对误差 (MAE)：评估模型预测值与实际值的平均绝对误差，公式为：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (16)$$

平均相对误差 (MRE)：评估模型预测值与实际值之间的相对误差，公式为：

$$MRE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (17)$$

决定系数 (R^2)：衡量模型对数据的解释能力，公式为：

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (18)$$

3.4.2 密度-速度关系

通过最小二乘法，分别结合实际交通流的数据对三个模型进行拟合。由表 4 可知，**Van Aerde 模型**在所有观测点中表现最好，尤其在观测点 D 中， R^2 达到 0.87，模型拟合效果较好。即使在观测点 C，尽管误差较大，它仍然是表现最好的模型。**Greenberg 模型**的表现最差，MSE 和 MAE 在所有观测点中都较高， R^2 最低，尤其在观测点 A 和 B 中表现较差。进一步说明，该交通流不适用于连续交通流方程。

表 4 密度-速度模型评估结果

观测点	交通流模型	MSE	MAE	MRE	R^2
A	Van Aerde 模型	4.35	1.83	0.03	0.47
	Pipes 模型	5.76	1.99	0.03	0.30
	Greenberg 模型	6.30	2.05	0.03	0.23
B	Van Aerde 模型	4.35	1.84	0.03	0.47
	Pipes 模型	5.76	1.99	0.03	0.30
	Greenberg 模型	6.31	2.05	0.03	0.23
C	Van Aerde 模型	96.53	8.68	0.13	0.44
	Pipes 模型	98.32	8.88	0.13	0.43
	Greenberg 模型	100.43	9.05	0.13	0.42
D	Van Aerde 模型	38.49	3.33	0.08	0.87
	Pipes 模型	45.15	3.83	0.09	0.85

如图 20 所示, Van Aerde 模型在所有观测点中表现优异,尤其是在低密度和中等密度区域。它在多个观测点中的 R^2 值最高,说明它更好地捕捉了数据的整体趋势。然而,在高密度区域,模型有时会出现较大的偏差,特别是在观测点 C 和 D 中表现出不足。Pipes 模型在各观测点中的表现相对稳定,曲线平滑,且在中等密度到高密度区域表现较好,但在低密度区域可能没有很好地捕捉数据的波动。因此,虽然其误差较低,但整体拟合效果不如 Van Aerde 模型。Greenberg 模型在低密度和中等密度区域的拟合效果最差,特别是当密度较小时,其曲线相对平坦,无法很好地反映数据的变化趋势。但在高密度区域,它的表现与数据更接近,适合高密度情况下的流量预测。

通过图中四个观测点的分析,可以得出密度与速度之间的反比关系较为明显,尤其是在中高密度区域,速度下降尤为显著。三种模型中, Van Aerde 模型适合低密度和中等密度的情况,而 Pipes 模型和 Greenberg 模型在高密度区域的拟合效果更佳。




图 20 密度-速度关系图

3.4.3 流量-密度关系

通过最小二乘法分别利用四个观测点的实际交通流数据对 Greenshields 模型 (线性关系)、Greenberg 模型 (对数关系)、Underwood 模型 (指数关系)、Drake 模型和 Van Aerde 模型 (反比关系) 进行拟合。如表 5 所示, Van Aerde 模型在所有观测点中的表现最佳,特别是在观测点 A 和 C 中, R^2 值分别为 0.90 和 0.66, 拟合效果明显优

于其他模型。其 MSE 和 MAE 也在所有观测点中表现最低，说明它是最适合描述流量与密度关系的模型。**Greenshields 模型**次之，在部分观测点（如 A、D）表现较好，但在其他观测点中的拟合效果一般，MSE 和 R^2 值均不如 Van Aerde 模型。**Drake 模型**在所有观测点中的表现最差，MSE 极高， R^2 值多次为负数，表明其在这些数据点上完全不适用。**Greenberg 模型**和 **Underwood 模型**的表现较为接近，但总体上不如 Van Aerde 模型的拟合效果好，尤其在高密度情况下，这两个模型难以捕捉流量的变化。

表 5 流量-密度模型评估结果

观测点	Model	MSE	MAE	MRE	R^2
A	Greenshields	10.60	2.69	0.10	0.80
	Greenberg	14.61	3.14	0.12	0.72
	Underwood	12.48	2.89	0.11	0.76
	Drake	415.57	16.85	0.58	-6.97
	Van Aerde	5.10	1.69	0.06	0.90
B	Greenshields	30.69	4.57	0.18	0.40
	Greenberg	34.99	4.91	0.20	0.31
	Underwood	33.39	4.76	0.19	0.34
	Drake	283.01	15.34	0.61	-4.56
	Van Aerde	20.82	3.16	0.12	0.59
C	Greenshields	13.69	3.02	0.11	0.46
	Greenberg	17.85	3.49	0.13	0.29
	Underwood	18.21	3.53	0.13	0.28
	Drake	337.20	16.22	0.59	-12.40
	Van Aerde	8.62	2.10	0.08	0.66
D	Greenshields	41.17	5.18	0.76	0.57
	Greenberg	43.57	5.16	0.69	0.54
	Underwood	42.09	5.13	0.71	0.56
	Drake	75.31	6.76	0.66	0.21
	Van Aerde	26.98	3.61	0.37	0.72

由图 21 可知：

低密度情况下的流量增加：在图中可以看到，当密度较低时，大多数模型的流量随着密度的增加而增加。这符合基本的交通流理论：在低密度条件下，车辆可以保持较高速度，且密度增加并未引起交通拥堵，因此流量能够上升。从图中来看，Greenshields 和 Greenberg 模型在这个阶段的表现较为理想，拟合结果较为接近观测数据。

高密度情况下的流量下降：当密度增加到一定程度后，车辆之间的干扰增大，流量达到峰值后开始下降。此时，交通流趋于饱和，车辆速度下降，流量也随之下降。图中的观测数据也显示出这一现象。大多数模型在这一阶段表现出良好的拟合效果，尤其是 Greenberg 模型能够较好地捕捉这种趋势，而 Underwood 模型在这一阶段的下降过于迅速，偏离了实际情况。

高密度拥堵效应：如观测点 D，密度继续增加时，流量趋于接近 0，说明该路段已经处于拥堵状态。此时车辆几乎无法移动，交通流量急剧减少甚至停止。Van Aerde 模型在这一阶段表现出过度拟合的趋势，其曲线形式未能很好地反映

出高密度下的实际交通状况，而 Greenshields 和 Greenberg 模型则更好地捕捉到了这种密度极高时流量趋于零的现象。

在每个观测点中，流量随密度的变化趋势基本保持一致，即随着密度增加，流量先增后降。不同观测点之间的差异主要体现在流量峰值的大小和密度临界点的不同，如观测点 D 的最大值出现在较低的密度处，而其他观测点的流量峰值则出现在较高的密度值。




图 21 流量-密度关系图

3.4.4 流量-速度关系

采用最小二乘法对实际交通流的流量-速度数据进行拟合分析。如表 6 所示，在观测点 A, B, C 中，几乎所有的指标值都非常的接近。**Van Aerde 模型**在大多数观测点的拟合效果不佳，特别是在观测点 D，它的表现最差。虽然在观测点 A 和 B 与其他模型表现接近，但整体而言，它的误差较大，解释能力较弱。**Pipes 模型**表现相对中等，特别是在观测点 C 和 D，虽然其误差高于 **Greenberg 模型**，但与 **Van Aerde** 相比具有更好的稳定性。**Greenberg 模型**在观测点 D 表现最好，具有较低的 MSE 和 MAE 以及较高的 R^2 。但在其他观测点的表现与 **Pipes 模型** 接近，说明其在某些情况下具有更好的拟合能力。各模型的拟合效果相差不大，但整体上拟合效果都较弱。

表 6 流量-速度模型评估结果

观测点	交通流模型	MSE	MAE	MRE	R^2
A	Van Aerde 模型	8.012	2.217	0.034	0.036

	Pipes 模型	8.156	2.238	0.034	0.018
	Greenberg 模型	8.110	2.231	0.034	0.024
	Van Aerde 模型	2.466	1.172	0.020	0.016
B	Pipes 模型	2.470	1.172	0.020	0.014
	Greenberg 模型	2.465	1.171	0.020	0.016
	Van Aerde 模型	169.563	11.271	0.168	0.017
C	Pipes 模型	172.454	11.135	0.167	0.000
	Greenberg 模型	172.595	11.132	0.167	-0.001
	Van Aerde 模型	1546.334	36.286	0.929	-4.096
D	Pipes 模型	221.797	12.878	0.350	0.269
	Greenberg 模型	179.421	10.979	0.293	0.409

所有模型的拟合效果较差，特别是 R^2 值接近于 0，说明这些模型在解释数据变化上非常有限。**基本交通流理论**指出，随着流量的增加，交通速度会先保持在较高水平，但随着道路饱和度的增加，交通速度会逐渐降低。换句话说，流量和速度之间的关系往往呈现**非线性**的特征。在低密度的交通条件下，车辆之间干扰较小，速度较高；而在高密度情况下，车辆之间的相互干扰增多，速度下降，直至发生交通拥堵。

如图 22 观测点 A，随着流量的增加，速度呈现出下降趋势，这与连续交通流理论中的典型非线性关系相符。流量增大的初期，车辆间距变小，驾驶员之间的相互干扰增多，速度开始下降。该观测点的数据点比较分散，尤其在高流量下，速度的波动很大。这可能意味着该点位的交通情况较复杂，可能受到了不同的交通控制因素、道路条件或车辆类型的影响，导致了流量与速度之间关系的波动。模型在拟合过程中难以精确捕捉这种关系。虽然速度随着流量的增加而下降，但由于数据点的离散性，模型难以完全反映其变化趋势。

如图 22 观测点 B，显示了更为清晰的流量与速度的线性负相关关系。随着流量增加，速度缓慢下降，车辆的速度受到更多前车的影响。这种线性趋势常见于较低密度的交通流。该观测点的流量范围较小，速度表现相对稳定，意味着交通流在该点位尚未达到饱和状态，没有发生严重的拥堵现象。**Pipes** 模型拟合效果最好，原因在于 **Pipes** 模型假设速度与密度呈线性关系，能够很好地捕捉该点的流量与速度之间的简单线性关系。

如图 22 观测点 C，流量与速度的关系变得更加复杂。低流量时，速度相对较高；而随着流量逐渐增加，速度开始下降。然而，随着流量进一步增加，速度反而有所上升。这种现象可能反映了交通系统中的一些特殊情况，比如部分路段交通流的改善，或者车辆加速通过某些瓶颈路段的情况。图中的数据点波动较大，可能说明该路段受外界因素干扰较多，可能存在不稳定的交通流状况，比如信号灯、交叉路口或其他交通控制措施的影响。**Van Aerde** 和 **Pipes** 模型未能很好地解释这种非典型的波动现象，而 **Greenberg** 模型在这里稍微表现好一些，说明 **Greenberg** 模型在处理复杂流量变化时更具弹性。

如图 22 观测点 D，流量在 10 以下时，速度的表现非常异常，尤其是 **Van Aerde** 模型预测的速度出现了极高的峰值。这种现象在连续交通流中是罕见的，

通常表明模型拟合出现了问题。在高流量下，速度表现出较为平稳的下降趋势，这符合交通流理论，即在拥挤的交通流中，速度趋于较低且稳定。该点可能存在异常数据点，尤其是在低流量下，由于道路条件或交通管理的原因，可能存在一些特殊的交通行为（如临时停车、拥堵等），导致了速度的异常波动。

总体来说，这些观测点反映了**流量与速度之间的复杂非线性关系**。在低流量条件下，速度相对较高，但某些观测点出现的速度波动提示我们在实际交通中可能受到外界条件的干扰。在高流量条件下，速度下降趋势明显，符合拥堵状态下的交通流规律。




图 22 流量-速度关系图

3.5 基于间断交通流方程的交通流拥堵预警模型

3.5.1 模型建立

在高峰时段，上游车流的增长会在几分钟内反映到下游。在视频的开始阶段都有一个初始的交通状态。从 A 点到 D 点没有出入口，上下游的车道数量是相同的，过了 D 点之后有一个服务区入口，上下游的路段限速也是相同的。因此在 A-D 路段，没有额外的车辆进入或离开上下游区间，可以认为流量是守恒的，在不开放应急车道的情况下，上下游的通行能力都是不变的，上游流量可以直接用于推测下游流量。此时的流量、密度、速度满足如公式(9)。

如果当下游某点的密度发生改变，导致交通流发生间断，上游的交通流量又很大，才会在下游继续发生拥堵。给定了一个拥堵的速度范围之后，假设初始密度都是稀疏的，也就是不拥堵的，车辆在车道上面正常行驶。在这种情况下面拥堵的流程应该是：第四点首先发生拥堵，然后密度形成间断，后续车辆开始跟上，只要第四点没有疏通，拥堵会一直向后延伸。因此第四点的作用就是判断拥堵是

否形成以及何时疏散，后续点位的作用就是用来辅助判断拥堵的持续时间。因此就可以利用间断交通流模型去进行时间的计算。

(1) 间断交通流方程

当密度函数 $\rho(x, t)$ 出现间断时，具有实际意义的也是常见的一种情况是，一连串的间断点 (x, t) 在 $x \sim t$ 平面上构成一条孤立的、连续的间断线，记作 $x = x_s(t)$ ，假定它是可微分的。在任意时刻 t ， $x = x_s(t)$ 在 x 轴上是孤立的，可以取区间 $[a, b]$ ，使 $a < x_s(t) < b$ 。在 $[a, b]$ 内交通流方程的积分形式仍然成立。将 $[a, b]$ 分为两个区间 $[a, x_s(t))$ 和 $(x_s(t), b]$ ，在每个区间内 $\rho(x, t)$ 是连续，可微的，于是：

$$\begin{aligned} q(a, t) - q(b, t) &= \frac{d}{dt} \left[\int_a^{x_s(t)} \rho(x, t) dx + \int_{x_s(t)}^b \rho(x, t) dx \right] \\ &= \int_a^{x_s(t)} \frac{\partial \rho}{\partial t} dx + \rho(x_s^-(t), t) \frac{dx_s}{dt} + \int_{x_s(t)}^b \frac{\partial \rho}{\partial t} dx - \rho(x_s^+(t), t) \frac{dx_s}{dt} \end{aligned} \quad (19)$$

其中 $x_s^-(t)$ 和 $x_s^+(t)$ 分别表示从小于和大于 $x_s(t)$ 一侧趋向 $x_s(t)$ 时的极限值。在这种趋向下 $\rho(x, t)$ 和 $q(x, t)$ 的极限值记作：

$$\begin{aligned} \rho^- &= \rho(x_s^-(t), t), \quad \rho^+ = \rho(x_s^+(t), t) \\ q^- &= q(x_s^-(t), t), \quad q^+ = q(x_s^+(t), t) \end{aligned} \quad (20)$$

ρ 和 q 在间断点 x_s 处的跳跃值记作：

$$[\rho] = \rho^+ - \rho^-, [q] = q^+ - q^- \quad (21)$$

当 $a \rightarrow x_s^-(t), b \rightarrow x_s^+(t)$ 时：

$$[q] = [\rho] \frac{dx_s}{dt} \quad (22)$$

或记作：

$$\frac{dx_s}{dt} = \frac{[q]}{[\rho]} \quad (23)$$

这就是间断线 $x = x_s(t)$ 应满足的方程，其中 $[\rho]$ 和 $[q]$ 可以用连续交通流方程解得的 ρ 和 q 在间断点处取极限值算出。



图 23 高速路段

(2) 交通流拥堵模型

如图 23 所示, 该高速路段共有 ABCD 四个观测点, 假设四个监控观测点在 t 时刻的车辆密度为 $\rho_1(t), \rho_2(t), \rho_3(t), \rho_4(t)$ 。为了方便计算, 设 D 点为 $x=0$ 处, 若原来公路上的交通处于稳定壮大, 即初始密度 $f(x)$ 是常数。假设 D 处的监控发现时刻 t 后 τ 时间段内车速达到拥堵状态, 而后面 ($x < 0$; 第一点、第二点) 的车流密度 $\rho_1(t), \rho_2(t)$ 很大, 拥堵波快速向后传播, 则车辆开始由 D 点向最后一辆辆的堵塞起来。

设初始密度均小于使流量达到最大的密度 (稀疏流)。 $t = 0^+$ 时, D 点发生堵塞, 经过时间 τ 后, D 点交通又恢复通畅。D 点的拥堵, 导致在 D 点后面 ($x < 0$) 车辆堵塞导致最大密度 $\rho = \rho_m$ 与初始密度 $\rho = \rho_0$ 形成间断, 这条间断线记作 $x = x_s(t)$, 表示堵塞的车队尾部随时间向后延伸的过程。 $x_s(t)$ 由公式(23)确定, 所以, 对于 $x = x_s(t)$,

$$[q] = q(\rho_m) - q(\rho_0) = -\frac{u_m \rho_0 (\rho_m - \rho_0)}{\rho_m} \quad (24)$$

于是

$$\begin{cases} \frac{dx_s}{dt} = -\frac{u_m(\rho_0)}{\rho_m} \\ x_s(0) = 0 \end{cases} \quad (25)$$

其解为

$$x_s(t) = -\frac{u_m \rho_0}{\rho_m} t \quad (26)$$

当 $\tau < t$ 时, D 点的拥堵开始疏通。用 $x_1(t)$ 表示堵塞车队行驶时最前面那辆车的位置, 即 $\rho = 0$ 变为 $\rho > 0$ 那一点的位置; 用 $x_2(t)$ 表示堵塞车队行驶时最后面那辆车的位置, 即由 $\rho < \rho_m$ 变为 $\rho = \rho_m$ 那一点的位置, 将时间坐标平移为 $t' = t - \tau$, 初始密度 ($t' = 0$) 可记作:

$$f(x) = \begin{cases} \rho_m, & x_s < x < 0 \\ 0, & 0 < x \\ \rho_0, & x < x_s \end{cases} \quad (27)$$

对于 $0 < x$ ，由连续交通流方程可得 $\varphi(f(x_0)) = u_m$ ，在特征线 $x = u_m t' + x_0$ 上，密度 $\rho(x, t') = 0$ ，令 $x_0 \rightarrow 0^+$ 我们得到 $x_1(t') = u_m t'$ ，或：

$$x_1(t) = u_m(t - \tau) \quad (28)$$

因为最前面的那辆车能以最大速度 u_m 行驶，因此公式(28)可以立即写出。因此，对于 $x_s < x < 0$ ， $\varphi(f(x_0)) = -u_m$ ，

$$x_2(t) = -u_m(t - \tau) \quad (29)$$

而对于 $x_2(t) \leq x \leq x_1(t)$ ，密度 $\rho(x, t)$ 实际上是连续的，可知 $x = \varphi(\rho)t'$ ，因此：

$$x = u_m \left(1 - \frac{2\rho}{\rho_m}\right)(t - \tau) \quad (30)$$

即：

$$\rho(x, t) = \frac{\rho_m}{2} \left[1 - \frac{x}{u_m(t - \tau)}\right], x_2(t) \leq x \leq x_1(t) \quad (31)$$

假设 $t = t_d$ 时，堵塞消失。由于 $x_1(t)$ 和 $x_2(t)$ 向前向后的移动速度都是 u_m ， $x_s(t)$ 向后移动的速度为 $\frac{u_m \rho_0}{\rho_m}$ ，在 $\rho_0 < \rho^* = \rho_m/2$ 的假定下， $x_2(t)$ 赶上 $x_s(t)$ 的时刻为 t_d 。令 $x_s(t_d) = x_2(t_d)$ ，即 $u_m(t_d - \tau) = \frac{u_m(\rho_m - \rho_0)}{\rho_m} t_d$ 可得：

$$t_d = \frac{\rho_m}{\rho_m - \rho_0} \tau \quad (32)$$

显然 t_d 是堵塞完全消失的时刻，由于只需要考虑 C 点到 D 点的持续拥堵的时间，因此可对持续拥堵进行定义：当 $x_2(t)$ 赶上 $x_s(t)$ 得位置正好是 C 点时，此时时间 t_d 为持续拥堵时间（假设是 30 分钟），与之对应的 τ 就是 D 点拥堵的时间。

当 D 点发生拥堵时的初始密度是 ρ_0 ，要想 CD 段不发生持续拥堵，D 点拥堵的时间不能超过 τ ，如果拥堵时间大于 τ ，CD 段的拥堵时间将会大于 30 分钟。由公式(32)，针对 D 点的最长拥堵时间 τ 有以下公式：

$$\tau = \frac{(\rho_m - \rho_0)}{\rho_0} t_d \quad (33)$$

(3) 预警时刻模型

设 t_e 为预警时刻， t_r 为 D 点发生拥堵的时刻，提前 t 分钟进行预警，由公式(33)得：

$$t_e = t_r + \tau - t \quad (34)$$

$$t_e = t_r + \frac{(\rho_m - \rho_0)}{\rho_0} t_d - t \quad (35)$$

3.5.2 预警方法

当观测点 D 观测到 D 点监控范围发生拥堵，此时因为密度间断，会得出一个初始密度和一个拥挤密度。然后通过拥挤密度 ρ_m 和初始密度 ρ_0 ，去估算在此密度条件下，D 会可以拥堵的最短时间。因为预警需要提前十分钟，如果在距离极限拥堵时刻的 **10 分钟**时，D 点的拥堵还没有解除，将执行预警机制，代表可能会发生持续拥堵，如图 24 所示。相关定义如下：

持续拥堵定义：CD 段的拥堵持续 30 分钟，则认为 CD 段发生持续拥堵，此时对应的 $t_d = 30$ 。

提前预警时间：若预测 CD 段将会发生持续拥堵，预警的时间为提前十分钟。




图 24 基于交通流拥堵模型的预警机制

3.6 基于上游密度特征的下游交通流密度预测模型

针对基于间断交通流建立的交通流预警模型，只能实现到达预警时刻之后，随着拥堵的持续，CD 段发生持续拥堵的概率会越来越大。如果 10 分钟后 D 点拥堵正好疏散，根据间断交通流理论，CD 段将不会发生持续拥堵。为了更准确的进行预警，对十分钟后 D 的密度进行进一步的预测，加强预警的准确性。

3.6.1 不同观测点交通流参数的时间传递关系

在高速公路中，上游的车流会在若干时间后会抵达下游。如图 25 所示，假

设在 t 时刻，区域 D 的流量、密度特征在一定程度与 $t - \Delta t_1$ 时的区域 C 的流量密度特征有关；同理，也与 $t - \Delta t_2$ 时的区域 B， $t - \Delta t_3$ 时区域 A 的流量密度特征有关。因此，可以通过观测点 A,B,C 统计到的流量、密度和速度特征预测观测点 D 的流量、密度和速度特征，从而判断是否拥堵。




图 25 基于上游流量特征预测下游特征

如图 26 所示，是 4 条观测点的密度曲线及平滑后的结果。可以看出，这些曲线均具有前半程密度大，而后半程密度较小的特点，呈现“Z”形。无论在何种时间段，观测点密度在时间上总具有一定的传递性，从上游观测点 A,B,C 依次传递到观测点 D。具体来说，由于三个观测点之间存在一定的距离，所以存在一定的时间滞后，下一个观测点的“Z”形曲线可以通过上一个观测点的“Z”形曲线在时间轴 t 上平移获得。由于 A,B,C 三点的距离较近（1km），所以它们平移的 Δt 较小。而最后一个观测点 D 距离 C 口的距离较远（3km），所以时间滞后情况最为明显，平移量 Δt 相对较大。




图 26 四个观测点密度曲线及时间传递特征

如图 27 所示，通过研究各观测点之间密度特征的相关性，发现 A,B,C 观测点 10 分钟前的密度与观测点 D 之间的相关性分别为 0.73, 0.75 和 0.79，都在 0.7 之上，这表明观测点之间的密度特征具有较强的相关性，可以据此作为依据进行回归预测。此外，由于观测点 A,B,C 与观测点 D 之间的距离 $AD > BD > CD$ ，得到的系数为 0.73, 0.75 和 0.79，表明距离越近，相关性越强。




图 27 各观测点之间的密度相关性

3.6.2 基于多元线性回归的密度预测

(1) 模型建立

为了实现提前 10 分钟预测，我们需要使用 10 分钟前多个观测点的密度特征，预测 10 分钟后观测点 D 的密度大小。因此，对于输出的特征必须是 10 分钟前（相对于 D 点）观测点 A,B,C 的密度特征。训练数据集如表 7 所示。

表 7 数据集示例

time	A 观测点密度	B 观测点密度	C 观测点密度	D 观测点密度 (10 分钟后)
2024-05-01 13:02:00	192.4	226.3	227.0	310.9
2024-05-01 13:03:00	187.6	222.5	226.4	306.0
2024-05-01 13:04:00	187.0	224.8	222.3	298.5
...	...	...	...	...
2024-05-01 15:03:00	133.8	175.1	209.2	67.8
2024-05-01 15:04:00	134.5	173.3	203.8	64.8
2024-05-01 15:05:00	129.5	164.4	199.1	62.0

多元线性回归假设因变量 y 是自变量的线性函数，可以表示为:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon \quad (36)$$

其中:

- y 是目标变量 (因变量)。
- $x_1, x_2, \dots, x_n$ 是自变量 (特征)。
- β_0 是截距项，表示当所有自变量为零时，目标变量的值。
- $\beta_1, \beta_2, \dots, \beta_n$ 是回归系数，表示每个自变量对目标变量的影响。
- ϵ 是误差项，表示模型无法解释的噪声或随机误差。

多元线性回归的目标是找到一组回归系数 $\beta_1, \beta_2, \dots, \beta_n$ ，使得预测值与实际值之间的误差最小化，采用最小二乘法来最小化预测值和实际值之间的平方误差之和，如公式(37)

$$\min \sum_{i=1}^m (y_i - (\beta_0 + \beta_1 x_{i1} + \dots + \beta_n x_{in}))^2 \quad (37)$$

在本文中，根据 A,B,C 三个路段当前的交通密度来预测 10 分钟后 D 的交通密度。所以多元线性回归的基本形式为：

$$\rho_d = \beta_0 + \beta_1 \rho_a + \beta_2 \rho_b + \beta_3 \rho_c + \epsilon \quad (38)$$

其中，通过代入表 7 的数据后，利用最小二乘得到 $\beta_0, \beta_1, \beta_2, \beta_3$ 的值分别为 198.7, 60.1, -44.7 和 89.4，它们表示 A,B,C 观测点密度 10 分钟后 D 观测点密度的影响。因此，得到最终的回归表达式为表达式(39)，通过此公式就能提前 10 分钟预测得到下游密度，如果密度达到最大密度的 80%，就提前进行预警。

$$\rho_d = 198.7 + 60.1\rho_a - 44.7\rho_b + 89.4\rho_c + \epsilon \quad (39)$$

(2) 模型验证

如图 28 红色的点所示，是该回归公式计算得到的预测值与实际值，虽然二者整体趋势较为一致，但有些预测值和真实值之间差距还是较大。通过计算，得到预测值和实际值的平均绝对误差为 47.4veh/km，预测值和真实值的皮尔逊相关系数也能达到 0.8455，该结果不够良好，因此，本文进一步采用了 AdaBoost 机器学习回归模型，以提升预测精度。




图 28 多元回归预测值和实际值之间的对比

3.6.3 基于 AdaBoost 回归的密度预测

(1) 模型建立

由于基于多元线性回归的密度预测精度有限，因此利用 AdaBoost 回归模型对密度预测进行改进。AdaBoost 回归算法是由 Freund 和 Schapire^[23]在 1996 年提出的经典的基于自适应增强策略的集成学习算法，该算法是通过组合多个性能较弱的回归器^[24]，形成一个更强大的回归模型。通过这种组合，能够显著提升模型的整体预测能力，算法示意图如图 29 所示。




图 29 AdaBoost 算法示意图

在自适应迭代过程中，多个弱回归器彼此相关，每个弱回归器的预测误差将影响下一次迭代中样本的权重分布^[25]。通过这种权重更新机制，AdaBoost 引导模型在后续迭代中更加关注那些难以预测的样本，从而提高整体模型的预测效果。

具体步骤如下：

首先，在算法的初始阶段，所有的训练样本被赋予相等的权重。此时，每个样本对模型训练具有相同的重要性。

$$D_1(i) = (w_1, w_2, \dots, w_N) = \frac{1}{N} \quad (40)$$

然后执行迭代过程，设定迭代次数为 $t = 1, \dots, T$ ，其中 $\mathcal{X}$ 表示输入空间， y_i 表示实际的目标值， $\hat{y}_i$ 为预测值。计算弱回归器 $h_t(\mathcal{X})$ 在权重分布 D_t 下的误差 ϵ_t ，该误差衡量当前弱回归器对整体样本的预测效果。

$$\epsilon_t = \frac{\sum_{i=1}^N w_n(t) \cdot |h_t(x_i) - y_i|}{\sum_{i=1}^N w_n(t)} \quad (41)$$

其中，误差 ϵ_t 是加权的绝对误差，反映了当前弱回归器的性能。

然后，根据误差大小计算该弱回归器在最终模型中的权重 α_t 。弱回归器的权重反映了其在组合模型中的重要性，误差越小，权重越高。

$$\alpha_t = \log \left(\frac{1 - \epsilon_t}{\epsilon_t} \right) \quad (42)$$

接下来，更新每个样本的权重分布 D_{t+1} ，误差较大的样本将获得更高的权重，而预测效果较好的样本则会降低权重。

$$D_{t+1}(i) = D_t(i) \cdot \exp(|h_t(x_i) - y_i|) \quad (43)$$

这个过程确保在后续迭代中，模型会越来越聚焦于那些预测误差较大的样本，不断优化模型的预测效果。经过 T 次迭代后，AdaBoost 通过组合所有弱回归器，并按它们的权重 α_t 加权汇总，形成最终的强回归模型：

$$H(x) = \sum_{t=1}^T \alpha_t \cdot h_t(x) \quad (44)$$

(2) 模型验证

对于视频 D 得到的数据总共有 134 分钟，也就是有 134 个样本点，按照 0.7:0.3 的比例划分，得到训练集和测试集分别为 94 和 40。模型的输入特征就是观测点 A,B,C 的车流量密度，而预测值就是 10 分钟后观测点 D 的密度。在测试集数据中，模型的平均绝对误差为 11.2veh/km，均方根误差为 19.9veh/km， R^2 值为 0.968，效果显著优于多元线性回归预测模型，测试集的预测结果展示如图 30 所示。

如图 31 所示，是观测点 A,B,C 密度对于预测观测点 D 密度的重要性分析，相当于在预测过程中的贡献度水平。可以看出，C 的重要性>B 的重要性>A 重要性，这与实际观测点之间的距离成反关系，说明距离越远，贡献度越小，符合一般规律。




图 30 观测点 D 的实际密度和 AdaBoost 模型的预测密度




图 31 观测点 A,B,C 密度对预测观测点 D 密度的重要性对比

3.6.4 基于密度预测模型改进的交通流拥堵预警方法

当通过观测点 D 的监控数据发现 D 点发生拥堵，通过交通流拥堵模型计算

预警时刻。到达预警时刻之后，通过密度预测模型进一步预测 D 点 t 时刻（t 为定义的提前预警时间）之后的 D 点密度，如果 D 点密度达到拥堵密度，则判断 CD 段会发生持续拥堵，此时进行预警；如果 D 点密度没有达到拥堵密度，则不进行预警。预警流程如图 32 所示。

相关定义：根据最新的预警机制，需要定义什么是拥堵密度。由视频可知，观测点 D 在 14:05 之前一直存在交通拥堵情况，而通过前文“3.2.5 车流量信息统计”的图 14 的统计结果可知，在 14:05 之前密度大部分都在 300veh/h 以上，因此，我们定义在 D 处密度大于 300veh/km 时为交通拥堵，只要 D 观测点的密度达到拥堵密度的 80%，也就是 240veh/km，就进行实时预警。




图 32 基于密度预测模型改进的预警机制

3.7 基于视频信息的模型验证

3.7.1 拥堵阈值选择

因为每个观测点的数据都会受每个视频本身的影响，所以在判断是否拥堵的时候每个观测点都有自己的阈值。

如图 33 所示，由观测点 A 流量-密度关系图可知，当密度达到 200veh/km

时, 流量达到最大值 2700veh/h。此时随着密度的增大, 流量下降明显, 根据连续交通流方程可知, 此时达到拥堵状态。再由密度-速度图可知, 当密度达到 200veh/km 以后, 速度下降明显, 此时对应的速度主要集中在 64km/h 以下。因此, 针对观测点 A, 最大密度为 300veh/km, 当密度达到 200veh/km 时开始拥堵, 速度阈值为 64km/h, A 点的最大流量为 300veh/h。

由观测点 B 流量-密度图可知, 当密度达到 250veh/km 时, 流量达到最大值 2500veh/h, 此时随着密度的增大, 流量下降明显, 根据连续交通流方程可知, 此时达到拥堵状态。由密度-速度图可知, 此时对应的速度区间为 48km/h-60km/h, 由流量-速度关系图可知, 观测点 B 的速度区间主要集中在 58-60km/h。因此, 针对观测点 B, 最大密度为 400veh/km, 当密度达到 250veh/km 时开始拥堵, 速度阈值为 68km/h, 最大流量为 3000veh/h。

如图 34 所示, 由观测点 C 流量-密度关系图可知, 当密度达到 250veh/km 时, 流量达到最大值 2700veh/h。此时随着密度的增大流量下降明显, 根据连续交通流方程可知, 此时达到拥堵状态。再由密度-速度关系图可知, 当密度达到 250veh/km 以后, 速度区间为 50-80km/h, 但是根据点位密集度, 速度主要集中在 58km/h 以下。因此, 针对观测点 C, 最大密度为 400veh/km, 当密度达到 250veh/km 时开始拥堵, 速度阈值为 58km/h, 最大流量为 2700veh/h。

由观测点 D 流量-密度关系图可知, 当密度达到 250veh/km 时, 流量达到最大值 2400veh/h。此时随着密度的增大流量下降明显, 根据连续交通流方程可知, 此时达到拥堵状态。再由密度-速度关系图可知, 当密度达到 250veh/km 以后, 速度区间为 25-65km/h, 根据点位密集度, 速度主要集中在 30km/h。因此, 针对观测点 D, 最大密度为 350veh/km, 当密度达到 240veh/km 时开始拥堵, 速度阈值为 30km/h, 最大流量为 2400veh/h。




图 33 观测点 A 和 B 交通流数据




图 34 观测点 C 和 D 的交通流数据

3.7.2 数据来源

通过观察 D 点视频数据，发现在视频开始阶段发生拥堵，选取一拥堵段用于验证模型。如图 35 所示，D 点的视频开始时间为 12:56，这时已经开始发生拥堵，通过比较各观测点的密度，B 点和 C 点相继发生拥堵，符合交通流拥堵波的传播特点。




图 35 各观测点密度比较

通过观察视频数据，发现 D 点在 12:56 发生拥堵，此时速度达到拥堵速度，因为拥堵波的时间传递性，进一步观察后续观测点的拥堵情况，可以发现 C 点和 B 点分别在 13:26 和 13:33 发生拥堵，但是 A 点在关联的时间段并没有发生拥堵，根据交通流方程可知，拥堵波并未传播到 A 点，此时的堵塞完全消散。通过密度-速度图可知，观测点 A 的密度一直处于一个较低的水平，速度处于一个较高的水平，进一步验证了该路段没发生拥堵情况。如图 36 所示，通过观察实际视频的路况，验证了数据的真实性，车辆在相应的时间点都发生了拥堵。注意，这里的堵塞并不是完全堵塞，而是以一个相对拥挤的速度行驶。根据实际视频数据提取发生持续拥堵的数据，验证数据如表 8 所示。



图 36 各个观测点实时路况

表 8 观测点 B, C, D 的拥堵状况

观测点	拥堵时刻	疏散时刻	持续时间
D	12:56	14:06	60min
C	13:26	14:01	36min
B	13:33	13:57	25min

3.7.3 模型验证

验证思路：在 3.6 中依据对密度预测的精度进行了验证，因此，此处只针对交通流拥堵模型的验证。在已知拥堵时刻、疏散时刻、拥堵密度和达到拥堵密度之前的初始密度的情况下，计算在该点拥堵的持续时间 τ ，并于实际的拥堵持续时间进行对比，判断是否发生拥堵。

持续拥堵定义：以 D 点为例，设当 D 点从堵塞到完全疏通的时间超过 30 分钟时，说明 CD 路段发生持续拥堵。由公式(32)可知， $t_d = 30$ 。

如表 9 所示，D 点拥堵的时刻为 12:56，对应的 $\tau = 60$ 分钟，C 点拥堵的时刻为 13:24，对应的 $\tau = 36$ 分钟，B 点的拥堵时刻为 13:32，对应的 $\tau = 25$ 分钟。根据 D 点拥堵时刻和 C 点疏散时刻发现，CD 段的持续拥堵时间大于 30 分，判断 CD 段发生持续拥堵。根据 B 点的疏散时刻和 C 点的拥堵时刻，发现 BC 段的持续拥堵时间小于 30 分钟，因此 BC 段未发生持续拥堵。因此，可以根据这两段拥堵情况去验证模型的有效性，再根据其中提供的密度信息，通过公式(33)，计算预测的持续拥堵时间，并进行验证

表 9 计算参数

观测点	拥堵时刻	疏散时刻	持续时间	初始密度 ρ_0	拥堵密度 ρ_m
D	12:57	14:06	60min	165veh/km	350veh/km
C	13:26	14:01	35min	230veh/km	350veh/km
B	13:32	13:57	25min	156veh/km	300veh/km

由于定义持续拥堵的时间是 30 分钟，这确定该路段发生拥堵，那么根据 D 点密度发生突变的初始密度和形成堵塞的密度，可以计算出 D 点的最短的拥堵持续时间，那么根据公式(34)可算出预警时间，假设需要提前十分钟预警。

如表 10 所示，利用两端的拥堵情况去验证拥堵预警模型的有效性，D 点拥堵的时刻是 12:57，CD 段的持续拥堵时间大于 30 分钟，所以是发生持续拥堵的，D 点的实际拥堵持续时间为 60 分钟，通过交通流拥堵模型计算出来的最短拥堵持续时间为 25 分钟，小于实际的拥堵持续时间，因此发出预警，并计算预警时刻为 13:16。C 点的拥堵时刻 13:26，BC 段的持续拥堵时间小于 30 分钟，所以是不发生持续拥堵的，C 点的实际拥堵持续时间为 35 分钟，通过交通流拥堵模型计算出的允许的最短拥堵持续时间为 38 分钟，大于实际额拥堵持续时间，因此不发出预警。

表 10 预警验证结果

拥堵 段	拥堵时刻	实际拥堵 持续时间	是否持续 拥堵	最短拥堵 持续时间	是否发出 预警	预警时 刻 t_e
CD	12:57	60min	是	25	是	13:16
BC	13:26	35min	否	38	否	无

根据上述结果，根据交通流拥堵模型都作为了正确的预警行为，进一步验证了预警模型的有效性。

四、问题二：应急车道启用决策依据

4.1 问题分析

问题二要求构建合理启用高速公路应急车道模型，为决策者提供临时启用应急车道决策的理论依据。首先根据实际交通状况，同时考虑上游和下游的车流特征制定应急车道的启用依据：上游路段达到了较为拥堵的状态；应急车道的开放不能造成下游路段的拥堵。通过建立基于区间占用率的应急车道启用模型，计算上下游的车流量差值积分作为依据二的量化指标。

4.2 应急车道的启用依据

CD 路段的交通拥堵是由于上游路段（BC 和 AB 段）的车辆较多，这些车辆在经过若干时间之后抵达 CD，而 CD 的最大通行能力 q_{CD} 是有限的，如果能够开发应急车道，就能够加大 q_{CD} ，从而缓解交通拥堵。此外，D 路口的密度不能过大，如果 D 路口本身密度过大，在 CD 中间开发应急车道后，车辆最终还是会在 D 路口形成拥堵。所以应急车道的启用依据如下：

依据一：上游路段车辆数较多，需要提前对 CD 开放应急车道；

依据二：下游路段不能处于拥堵状态。

依据三：应急车道利用率 U_i 如果低于一定水平就选择关闭应急车道。

其中，依据二可通过第一问的 YOLO 模型实时检测获取 D 处的密度，作为判断的量化依据，D 路口的拥堵密度为 300veh/km，开发应急车道决策时的依据二就是实时通过 YOLOv10+Bytrack 获取 D 观测点的密度，判断其是否小于 240veh/km。依据三需要通过 CD 区间内部增设一个监控点，利用第四问的车道利用率模型进行补充。在本问中提出“区间车辆占用率模型”，对上游车辆数定义量化指标，实现对“依据一”的量化描述。

4.3 基于区间占用率的应急车道启用模型

4.3.1 模型建立

如图 37 所示，以 BC 区间为例，B 处的车流量为 $q_B(t)$ ，C 处的车流量为 $q_C(t)$ ，当 $q_C(t)$ 持续小于 $q_B(t)$ 时，表明驶出车辆小于驶入车辆，从而导致车辆在区间 BC 内的车辆不断增加，这些车辆在若干时间后就会抵达下游 CD 段，因此，如果 BC 内的车辆占有率达到了 $80\%Q_{m-BC}$ ，就可以提前开放 CD 的应急车道。




图 37 区间车辆占有率示意图

因此，设 BC 路段之间的最大容量为 Q_{m-BC} （单位为辆），初始车辆数为 Q_{0-BC} ，从而得到公式(45)。

$$Q_{0-BC} + \int_0^t q_B(t) - q_C(t) dt > 0.8 Q_{m-BC} \quad (45)$$

其中, $\int_0^t q_B(t) - q_C(t) dt$ 就是随着时间增加, BC 区间内容的车辆增加数(车辆累积量), 当二者之和超过 $0.8Q_{m-BC}$, 说明 BC 段内的车辆就已经达到了最大容量的 80%, 说明很可能形成拥堵, 应该及时预警, 让下游 CD 启用应急车道。

因为 CD 路段作为下游, 开放应急车道后就更加疏通, 上游 C 路口的流量 q_C 增大, 从而缓解 BC 段内的交通拥堵。并且, 应急车道开放能够提前疏通 CD 内本身的车辆, 相当于为后续提供一个更大的缓冲空间。此外, 应急车道的开放直接地增大了 CD 段的通行能力。

但通常情况下, 应急车道是救生通道, 不能随意占用, 如果长时间启用应急车道会造成一定的交通隐患^[26], 因此, 需要设置判断条件来关闭应急车道, 当满足公式(46)条件时, 说明上游车辆已经不是很多, 就可以关闭应急车道。

$$Q_{0-BC} + \int_0^t q_B(t) - q_C(t) dt < 0.6 Q_{m-BC} \quad (46)$$

进一步地将公式(45)和(46)整理可得公式(47)。

$$\frac{Q_{0-BC} + \int_0^t q_B(t) - q_C(t) dt}{Q_{m-BC}} > 0.8, \text{ 开启} \quad (47)$$

$$\frac{Q_{0-BC} + \int_0^t q_B(t) - q_C(t) dt}{Q_{m-BC}} < 0.6, \text{ 关闭}$$

这就是判定是否开启和关闭 CD 应急车道的依据之一。令

$$K_{BC}(t) = \frac{Q_{0-BC} + \int_0^t q_B(t) - q_C(t) dt}{Q_{m-BC}} \quad (48)$$

$K_{BC}(t)$ 就是 BC 路段的车辆占有率, 它是时间 t 的不定积分函数, 可以基于 0-t 时间内的监控数据实时计算。

4.3.2 模型应用与分析

如表 11 所示, 前期阶 $q_C(t)$ 较大, $q_D(t)$ 较小, $q_C(t) - q_D(t)$ 大于 0, 车辆累积项 $\int_0^t q_C(t) - q_D(t) dt$ 大于 0。随着时间的增加, CD 路段车辆不断增多, 占用率 $K_{CD}(t)$ 增大, 当 $K_{CD}(t)$ 大于 0.8 之后, 就会造成交通拥堵。

中间阶段阶 $q_C(t)$ 减小, 而 $q_D(t)$ 显著增大, 因此 $q_C(t) - q_D(t)$ 小于 0, 车辆累积项 $\int_0^t q_C(t) - q_D(t) dt$ 也就小于 0, 占有率 $K_{CD}(t)$ 的值就减小, 使得交通拥堵得以缓解。而后期阶段, $q_C(t)$ 显著大于 $q_D(t)$, 如果持续保持该情况, 很可能就会再次形成拥堵。

表 11 C 观测点和 D 观测点的车流量

阶段	时间	$q_C(t)$	$q_D(t)$	$q_C(t) - q_D(t)$
前期阶段	2024-05-01 13:04:00	37.7	23.01	14.69
	2024-05-01 13:05:00	37.2	23.27	13.93
	2024-05-01 13:06:00	36.3	22.49	13.81
...		...	...	...

中间阶段	2024-05-01 14:09:00	21.6	37.96	-16.36
	2024-05-01 14:10:00	21.7	39.26	-17.56
	2024-05-01 14:11:00	21.8	40.69	-18.89
	2024-05-01 14:12:00	22.3	40.04	-17.74
	2024-05-01 14:13:00	22.2	38.35	-16.15
后期阶段	...	...	...	...
	2024-05-01 15:10:00	29.4	6.63	22.77
	2024-05-01 15:11:00	27.9	5.59	22.31
	2024-05-01 15:12:00	27.9	5.33	22.57

此过程可通过图 38 进行描述，蓝色区域代表了 CD 区间的车辆数累积值，加剧了交通拥堵，橙色区域代表了 CD 区间驶出车辆多与驶入车辆值的车辆数，能够缓解拥堵。

在视频中，D 观测点在 13:04 时就已经形成拥堵，后续蓝色区域的增加，表明该路段的拥堵正在加剧。但随着驶出流量 $q_D(t)$ 的增大，以及驶入流量 $q_C(t)$ 的减小，图中出现了橙色区域，表明区间占用率模型中的车辆累积项“ $\int_0^t q_C(t) - q_D(t) dt$ ”小于 0，因此，交通逐渐得到缓解，直到 14:10 分钟左右，交通不再拥堵，逐步恢复到正常的稀疏流。




图 38 CD 段车流量差值

同理，绘制 AB 和 BC 段的车流量差值积分模型结果如图 39 和图 40 所示，图中的蓝色和橙色区域交替出现，没有形成像 D 路口那样的严重的交通拥堵。而通过 ABC 路口的视频查看可知，相比于 D 路口，ABC 路口的实际交通情况虽然出现不间断的交通拥堵，但都只是短暂时间内的，并不像 D 路口如此严重。所以，说明该车道占用率模型能够用于描述路段之间的拥堵情况，为是否开启应急车道提供决策依据之一。




图 39 AB 段车流量差值




图 40 BC 段车流量差值

4.4 结论

根据以上描述和分析，可以得出以下结论：

- **应急车道的启用应基于上游路段的车辆占有率：**当上游路段（如 BC 段）的车辆占有率达到 80% 时，驶出车辆小于驶入车辆且车辆在区间内不断累积，应及时启用下游路段（CD 段）的应急车道以缓解即将形成的拥堵。
- **下游路口的车流密度必须控制在一定范围内：**应急车道的启用不能导致下游路段（如 D 路口）的车流密度过大，因此通过实时监控 D 路口的车流密度，确保其小于 240veh/km，以避免因应急车道启用而引发新的拥堵。
- **车辆占用率模型可用于合理启用应急车道：**基于区间车辆占有率的模型，通过计算上下游路段车辆的流量差值，可以有效预测拥堵情况，并为应急车道的启用提供量化依据。这种模型有助于决策者提前采取措施，缓解交通压力。
- **应急车道的关闭应依据上游路段车流恢复情况：**当上游路段车辆占有率

下降到 60%以下时，说明上游交通流量已经恢复正常，此时可以考虑关闭应急车道，避免长时间占用应急车道带来的安全隐患。

- **车辆占用率模型能有效描述路段间的拥堵情况：**通过分析不同路段的车流量差值，可以清楚地识别出潜在的拥堵区域，并通过图示的蓝色和橙色区域区分拥堵加剧或缓解的状态，为交通管理提供数据支持。
- **启用应急车道能够提升下游路段的通行能力：**通过提前启用 CD 路段的应急车道，不仅可以疏解该路段的拥堵，还可以加快上游 C 路口的车辆通过速度，从而进一步缓解整个交通系统的拥堵情况。

五、问题三：应急车道启用效果量化分析

5.1 问题分析

问题三需要利用监控数据设计合理规则或算法,实现实时决策是否启用应急车道,并量化根据模型启用应急车道的作用。在前两问中,利用 YOLOv10 和 ByteTrack 算法实现车流量、车流密度和速度的实时统计并设计了基于实时统计结果的应急车道启用判断依据和决策流程。因此,在本问中,将使用确定的决策流程对 AB 段和 BC 段进行计算,从而对 CD 段是否启用应急车道进行重演,对比启用应急车道前后效果,对交通缓解情况进行量化分析。要明确的是:对于是否启用 CD 路段的应急车道,是要基于上游的车道占有率作为依据,所以是对 AB 和 BC 路段建立占有率模型,从而计算 $K_{BC}(t)$ 和 $K_{AB}(t)$ 。而本问题中的量化分析是根据 CD 段拥堵时间大小作为评估依据,所以在本问针对 CD 段进行占有率建模计算分析。

5.2 基于占有率模型的应急车道启用流程

基于问题二,为启用应急车道,给出方案如下:

- **位置:** 应急车道设置于 CD 段
- **开启依据:** $0.4K_{AB} + 0.6K_{BC} > 0.8$ 且 $\rho_{DE} < 240\text{veh/km}$

首先需要计算上游 BC 和 AB 段的车辆占有率 $K_{BC}(t)$ 和 $K_{AB}(t)$,并根据相关性,给定比例系数 $a=0.4$, $b=0.6$ 来协同描述上游车量的占有率。在车辆占有率大于 0.8 的情况下,还需考虑 CD 本身的通行状态,若 CD 段畅通,则开启应急车道,反之则不然,如图 41 所示。




图 41 应急车道启用决策流程图

5.3 量化分析--应急车道启用前

对于 CD 路段，车流量数据开始时刻为 13:04，此时已经是较为拥堵状态，而拥堵解除时刻约为 14:10。因此，未开启应急车道时，从视频开始的拥堵到拥堵结束，持续时长约为 1 小时，该过程如图 42 所示。




图 42 CD 段拥堵与缓解过程

对于 CD 段，有两种方式可以计算 Q_m

方式一：已知在 13:29 时的密度最大，而 CD 段的长度为 3km，根据公式(49)，可计算 $Q_m=1271$ 辆。

$$Q_m = \rho_{MAX} \times L_{CD} \quad (49)$$

方式二：只要知道占有率模型中两个时刻的 K 值，也能够计算 q_m 。从密度统计量中可知 13:29 时的密度最大，所以假设此时的占有率 $K(13:29)$ 值也达到最大值为 1，从而得到第一个 K 值，在 14:10 时交通拥堵缓解了，所以此时的 $K(14:10)=0.8$ ，从而获得了第二个 K 值。该过程相当于在 13:29-14:10 之间，K 值从 1 降低到 0.8，所以根据公式(50)计算得到 $Q_m = 1193$ 。

$$\int_{13:29}^{14:10} q_D(t) - q_C(t) dt = (1 - 0.8)Q_m \quad (50)$$

取两种方式中的较大值 $Q_m = 1271$ ，从而有：

$$K(13:04) = 1 - \frac{\int_{13:04}^{13:29} q_D(t) - q_C(t) dt}{1271} = 0.672 \quad (51)$$

因此，CD 段的 $K(t)$ 的函数表示是如(52)所示，它是关于时间 t 变化量，代入

前文统计得到的 $q_C(t)$ 和 $q_D(t)$ 就能得到 $K(t)$ 的具体结果，如图 43 所示。前期阶段， K 值增大，拥堵加剧，直到 $K=1$ ，达到最拥堵状态。后续 K 值开始下降，降低到 0.8 以下，说明拥堵逐渐得到解除。

$$K(t) = 0.672 + \frac{\int_{13:04}^t q_C(t) - q_D(t) dt}{1271} \quad (52)$$




图 43 未启用应急车道时的 $K(t)$ 曲线

5.4 量化分析--应急车道启用后

启用应急车道后，CD 路段从两车道变成三车道，其通行能力能够提升，假设其通行能力提升了 30%，因此，积分中的 $q_D(t)$ 应该乘以 1.3，从而得到启用应急车道后的车道占用率函数 $K'(t)$ ，代入 CD 段实际的 $q_C(t)$ 和 $q_D(t)$ 后，能够得到 t 时刻的 K' 值大小，将其与未启用应急车道的 $K(t)$ 进行对比，绘制成如图 44 所示的结果。

$$K'(t) = 0.672 + \frac{\int_{13:04}^t 1.3q_D(t) - q_C(t) dt}{1271} \quad (53)$$




图 44 启用应急车道与未启用应急车道 $K(t)$ 曲线对比

5.5 结论

采用应急车道后， $K'(t)$ 曲线在 $K(t)$ 之下，说明启用应急车道后，拥堵情况得到了缓解。具体来说，开放应急车道后得到的效果可分如下几点：

- (1) 拥堵时间往后推迟了 3 分钟。
- (2) 拥堵的结束时间提早了 25 分钟。
- (3) 应急车道开发前，堵塞时间从 13:14 持续至 14:12，总计 58 分钟；开发后，堵塞时间总计 30 分钟，**堵塞时间降低了 48.3%**。
- (4) 应急车道启用后 $K(t)$ 曲线率峰值降低到 0.917，显著低于应急车道启用前的 K 值。

因此，开放应急车道对通行能力提升的效果显著，极大提高了 CD 段通行效率。

六、 问题四：视频监控点优化布置

6.1 问题分析

问题三需要重新布置视频监控点，在控制成本的情况下提升第三个点到第四个点之间路段应急车道启用决策的科学性。为了在不显著增加成本的情况下优化监控系统，考虑将 B 点的摄像头移至 D 点下游，设为 E 点。并基于问题三中的车辆占有率模型叙述撤走 B 点监控的原因，并叙述不撤走 A 点监控点的原因。考虑到 CD 区间较长，本文提议在 CD 区间内部布置一个摄像头 F，建立**应急车道利用率模型**，用于计算应急车道开发后的利用率水平 U，从而判断是否应该及时关闭应急车道。此外，更好的摄像头角度有利于交通流参数的监控，减少由于拥堵产生的车辆遮挡和漏检问题。最后，讨论了开放应急车道的安全性问题。

6.2 摄像头的区间位置优化

6.2.1 下游位置添加 E 点

在问题二中，只考虑了 D 点密度，未曾考虑下游密度，如果能在 D 的下游布置一个 E 摄像头，就可以对 DE 区间建模车辆占有率模型。通过计算 K_{DE} 来判断下游是否拥堵，从而决策 CD 是否能够开启应急通道。计算 K_{DE} 的作用与 ρ_D 的作用类似，都是为了确保应急车道的前方没有拥堵，而密度的统计是一个瞬时变量，波动性相对较大，而 K_{DE} 能够描述下游 DE 整个区间的拥堵情况，相比之下更加稳定和合理。所以，添加 E 点后，判断依据流程可以改善，如图 46 所示。



图 45 增加 E 检测点




图 46 应急车道是否开启判断依据流程图（添加 E 点后）

但为了不提高成本，可以撤走 B 处的摄像头，将其布置到 D 处的下游，将其成为 E 点。

撤走 B 处摄像头的原因

在问题 2 中的决策依据一中分别对 AB 和 BC 段建立的车辆占有率模型，得到 K_{AB} 和 K_{BC} ，但二者都是 CD 段的上游，它们所提供的信息本质上较为一致。因此，上游只需要保留 A 或 B 中的一个，与 C 点构成一个区间即可建立车辆占用率模型，从而为 CD 段应急车道的启用提供上游信息作为依据。

撤走 B 而不是撤走 A 的原因

ABC 三点距离较近，AB 段为 1 公里，BC 段也为 1 公里，而 CD 段的距离是 3 公里。所以，撤走 B 后，AC 段为 2 公里，但撤走 A 后，BC 就只有 1 公里， Q_{BC-max} 本身较小，根据占有率的定义公式(54)可知， K_{BC} 的灵敏度就较高，而 AC 的距离就比 BC 远一些，因此， $Q_{AC-max} > Q_{BC-max}$ ， $K_{AC}(t)$ 的灵敏度更低。

$$K_{BC}(t) = \frac{Q_0 + \int_0^t q_B(t) - q_C(t) dt}{Q_{BC-max}} \quad (54)$$

6.2.2 CD 区间内部添加 F 点

CD 区间相距 3km，相对较远，在前文中是基于少数摄像头的统计量对区间内车辆占用率进行建模分析，但难以获取区间内部各车道的利用率情况（尤其是应急车道），因此，如果成本允许，本文提议在 CD 内部再布置一个摄像头 F，建立车道利用率模型，用于检测开放后 CD 区间内应急车道的利用率，为关闭应急车道提供依据。

基于 YOLOv10 的车道利用率模型：通过 YOLOv10，能够对车辆路过区域生成热度图，热度图越亮的区域表明车辆利用率越高。基于该思路，可以计算路段中应急车道的利用率，作为开发应急车道之后关闭的依据，如果一段时间后利

用率降低到一定水平后，可以考虑关闭应急车道。



图 47 基于 YOLOv10 的车道占用热度图

由于热图中每个像素的值反映了该位置在一段时间内被车辆占用的频率，实际上反映了车辆在空间和时间上的分布密度。通过利用热图数据计算每个车道的利用率。从而对应急车道的关闭提供一个重要参考依据。

1.划分车道区域

如图 48 所示，将车道划分为三个区域 $R_i (i = 1, 2, 3)$ ， R_3 表示应急车道。




图 48 车道划分示意图

2.计算每个车道区域的热度总和

热度图的数值结果计算是基于每一帧中检测到的车辆结合衰减因子计算得到的，如公式(55)所示。

$$\text{heatmap}(t) = \alpha \cdot \text{heatmap}(t - 1) + \Delta H(t) \quad (55)$$

其中 $\Delta H(t)$ 是为第 t 帧中车辆贡献的热度增量。

3.车道利用率计算

对于应急车道 R_3 ，热度总和为公式(56)

$$H_3 = \sum_{(x,y) \in R_3} \text{heatmap}(x, y) \quad (56)$$

而车道利用率定义为当前热度总和与最大热度总和的比值，所以应急车道利

用率为公式(57)

$$U_3 = \frac{H_3}{H_{max,3}} \quad (57)$$

通过 U_3 就可以反应应急车道的利用率水平,从而进一步完善问题二中应急车道的开放依据,如果开发一段时间后应急车道的利用率水平不高,可以选择关闭该应急车道。

因此,将 U_i 作为关闭应急车道的重要依据后,最终应急车道开放流程如图 49 所示。




图 49 应急车道“开发/关闭”判断依据流程图（CD 区间内添加 F 点后）

6.3 摄像头的角度布置优化

在赛题的视频中,如果车流密度较大,车与车之间形成了遮挡,导致 YOLO 模型无法检测到被遮挡的车辆,而且是越拥堵,遮挡情况越严重,如图 50 所示。

在实际情况下,该问题可以通过修改摄像头的位置进行解决,比如,通过设置一个高架,将摄像头布置成从高处往下进行监测,形成一个俯视的角度,就能够很好地解决此问题。



图 50 过于拥堵造成的遮挡

6.4 安全性问题

本文建立的模型专注于高速公路应急车道的紧急启用，在缓解交通拥堵方面展现出了卓越的高效性和可靠性^[3]。尤其是在交通高峰期，节假日等特殊情况下，传统的交通管理措施常常无法有效应对急剧增加的车流量。通过本文模型，在特定时间段内开放应急车道，能够提升道路通行能力，有效缓解拥堵现象。尽管这一方案的效果显著，但启用应急车道不可避免地牺牲一定的安全性。然而，综合考虑来看，这种安全性的牺牲在特定情况下是有其合理性和必要性的，有以下几点原因：

(1) 效率与需求的平衡

在高峰期，交通需求往往超出道路的承载能力。在这种情况下，通过适度牺牲安全性，开放应急车道可以迅速提高通行速度，满足公众出行的迫切需求。

(2) 相对安全的考量

虽然启用应急车道可能增加一定的事故风险，但在严重拥堵情况下，车辆停滞不前可能导致更高的事故发生率。适度牺牲安全性有助于缓解车流，减少因长时间等待而导致的焦虑和不安，可能在整体上降低事故发生的概率。

(3) 应急响应的提升

开放应急车道可以为救援和应急车辆提供通行空间，提高响应速度。相较于偶尔出现的事故风险，快速处理紧急情况的能力可能在整体交通安全中占据更重要的地位。

(4) 技术辅助

通过实时交通监控和智能交通系统，能够更好地管理应急车道的使用情况，

及时应对突发事件。这意味着在牺牲一定安全性的同时，可以通过技术手段来降低风险，从而在提高通行效率的同时，增强安全保障。

（5） 成本效益分析

在进行交通管理时，需综合考虑成本与效益。在特定情况下，适当牺牲安全性所带来的通行效率提升，可能在整体社会效益上显得更加重要。对于大多数驾驶员而言，节省的时间和减少的拥堵能够带来更高的满意度。

（6） 公众认知与接受度

在某些情况下，公众对于安全与效率的权衡持开放态度，尤其是在特殊时段（如节假日）下，大家更倾向于理解和接受一定的安全风险，以换取更好的通行体验。

因此，虽然启用应急车道可能增加一定的事故风险，但在严重拥堵情况下，适度牺牲安全性有助于缓解车流，减少因长时间等待而导致的焦虑和不安，可能在整体上降低事故发生的概率。此外，通过实施实时交通监控和数据分析，可以更好地掌握路况变化，及时调整应急车道的启用状态，以尽量降低安全隐患。同时，建议在启用应急车道时，结合交通法规的宣传与教育，以增强司机的安全意识。同时，配备智能交通管理系统，实时监控车流量和驾驶行为，对违规行为进行及时警示和处理。这不仅能够维护交通秩序，还能在提高通行效率的同时，降低事故发生率。总之，本文提出的模型为高峰时间段的交通管理提供了一种高效的解决方案，在提升通行速度的同时，也为未来的应急交通管理实践提供了宝贵的经验和理论支持。通过合理的管理和科学的监控，可以在交通流畅与安全之间实现有效的平衡，从而为公众创造更为安全、顺畅的出行环境。

七、参考文献

- [1] 金梦媛. 考虑随机拥堵情况的快速路交通流短时预测方法研究[J]. 交通节能与环保, 2024, 20(3): 40-44+61.
- [2] 杨阳, 刘强, 石英杰. 高速公路饱和路段动态应急车道开放决策模型研究[J]. 公路工程, 2022, 47(3): 172-176.
- [3] 王磊, 李志轩. 基于智能交通系统的交通拥堵预测与缓解策略研究[J]. 运输经理世界, 2023(36): 77-79.
- [4] 宋静静. 突发拥堵状况下动态交通流信息预测研究[J]. 河南科技, 2024, 51(12): 19-23.
- [5] 田润泽. 高速公路交通拥堵识别和预判方法研究[D]. 桂林电子科技大学, 2024.
- [6] 邓宇豪. 道路口车流量检测及其信号灯配时算法研究[D]. 西安科技大学, 2024.
- [7] 肖的成. 基于视频的车流量统计和车道线检测研究[D]. 湖北师范大学, 2024.
- [8] 肖飞. 数据驱动的高速路网拥堵预测方法研究[D]. 中南大学, 2023.
- [9] 仲伟鹏. 基于深度学习的城市道路车辆检测与跟踪研究[D]. 南京林业大学, 2024.
- [10] 基于交通流基本图的交通拥堵预警方法研究_魏云凤[Z].
- [11] Sapkota R, Qureshi R, Calero M F, et al. YOLOv10 to its genesis: A decadal and comprehensive review of the you only look once (YOLO) series[A]. arXiv, 2024.
- [12] Alif M A R, Hussain M. YOLOv1 to YOLOv10: A comprehensive review of YOLO variants and their application in the agricultural domain[A]. arXiv, 2024.
- [13] Wang A, Chen H, Liu L, et al. YOLOv10: Real-time end-to-end object detection[A]. arXiv, 2024.
- [14] Qiu X, Chen Y, Cai W, et al. LD-YOLOv10: A Lightweight Target Detection Algorithm for Drone Scenarios Based on YOLOv10[J]. Electronics, 2024, 13(16): 3269.
- [15] Li Z, He Q, Yang W. E-FPN: an enhanced feature pyramid network for UAV scenarios detection[J]. The Visual Computer, 2024.
- [16] Zhu X, Lyu S, Wang X, et al. TPH-YOLOv5: Improved YOLOv5 Based on Transformer Prediction Head for Object Detection on Drone-captured Scenarios[M]. 2021: 2788.
- [17] Zhang Y, Sun P, Jiang Y, et al. ByteTrack: Multi-Object Tracking by Associating Every Detection Box[A]. arXiv, 2022.
- [18] 郭鹏宇. 轨迹和车流量预测研究及应用[D]. 电子科技大学, 2022.
- [19] Kalman R E. A new approach to linear filtering and prediction problems[J]. 1960.[J].
- [20] Kuhn H W. The Hungarian method for the assignment problem[J]. Naval Research Logistics Quarterly, 1955, 2(1-2): 83-97.
- [21] 杨东龙. 基于 arima 模型的区间道路短时车流量预测研究[J]. 电子设计工程, 2021, 29(13): 38-42.
- [22] 姜启源, 谢金星, 叶俊. 数学模型[M]. 北京: 高等教育出版社, 2003.
- [23] Freund Y, Schapire R E. Experiments with a New Boosting Algorithm[J].
- [24] Zhi N, An Y, Zhao Y, et al. Intelligent Island detection method of DC microgrid based on Adaboost algorithm[J]. Energy Reports, 2023, 9: 970-982.
- [25] Miller K. Boosting Algorithm in Python[EB/OL]. [2023-10-26]. <https://python-course.eu/machine-learning/boosting-algorithm-in-python.php>.
- [26] 高速公路饱和路段动态应急车道开放决策模型研究_杨阳[Z].

八、附录

- 1 yolov10+Bytrack 实现追踪与过线统计.py: 利用 YOLOv10 对视频进行信息提取的 python 代码
- 2 yolov10m.pt: YOLOv10m 模型权重文件
- 3 观测点 a_metrics.xlsx: 观测点 A 的视频数据获取结果
- 4 观测点 b_metrics.xlsx: 观测点 B 的视频数据获取结果
- 5 观测点 c_metrics.xlsx: 观测点 C 的视频数据获取结果
- 6 观测点 d_metrics.xlsx: 观测点 D 的视频数据获取结果
- 7 ARIMA 模型.py: 利用 ARIMA 模型对交通流数据进行特征计算和描述的 python 代码
- 8 平滑处理.py: 获取的交通流数据进行平滑处理
- 9 多元回归.py: 基于线性回归模型, 用上游密度预测 10 分钟后下游密度
- 10 AdaBoost.py: 基于 AdaBoost 模型, 用上游密度预测 10 分钟后下游密度
- 11 车道占用率模型_AB.py: 对 AB 段建立车道占用率模型
- 12 车道占用率模型_BC.py: 对 BC 段建立车道占用率模型
- 13 车道占用率模型_CD.py: 对 CD 段建立车道占用率模型
- 14 速度-密度关系拟合.py: 对观测点的速度-密度数据进行多模型拟合
- 15 流量-速度关系拟合.py: 对观测点的流量-速度数据进行多模型拟合
- 16 流量-密度关系拟合.py: 对观测点的流量-密度数据进行多模型拟合